

NLP Multitarea sobre Reseñas de Libros Goodreads

Predicción de rating · Detección de spoilers · Clasificación de emociones
Redes Neuronales 2025 — Universidad EAFIT

1. Problem Statement

Las plataformas de reseñas literarias como Goodreads generan millones de textos con información valiosa pero dispersa. Este proyecto aborda tres tareas de NLP de forma simultánea sobre el mismo corpus de reseñas del género Young Adult: (1) predicción de rating (1–5 estrellas), tarea que va más allá del análisis de sentimiento binario; (2) detección de spoilers, clasificación binaria con alto impacto práctico; y (3) clasificación de emociones (alegría, tristeza, enojo, sorpresa, miedo, disgusto), cuyas etiquetas se generan con el modelo j-hartmann/emotion-english-distilroberta-base como paso de preprocesamiento.

2. Dataset

Se utilizó el Goodreads Book Graph Dataset (UCSD, Wan & McAuley, RecSys'18 / ACL'19), compuesto por dos subsets: Young Adult reviews (2,389,900 reseñas) para rating y emoción, y Spoiler dataset (1,378,033 reseñas) para detección de spoilers. El input principal es review_text (texto libre), con labels rating (1–5), has_spoiler (booleano extraído de etiquetas en el texto) y emotion (generado por modelo pre-entrenado).

Data Splitting (estratificado por rating):

Split	Tamaño	Porcentaje
Train	70,000	70%
Validation	15,000	15%
Test	15,000	15%

3. Model Architecture

Se implementaron y compararon tres arquitecturas con complejidad creciente, todas con cabezas de salida para las tres tareas simultáneas:

MLP + TF-IDF (Baseline):

Vectorización TF-IDF (20k tokens) → Dense(256)+ReLU+Dropout(0.3) → Dense(128)+ReLU+Dropout(0.3) → cabezas: Dense(5)+Softmax (rating), Dense(1)+Sigmoid (spoiler).

Bi-LSTM Multitarea:

Embedding(20k×128) entrenable → BiLSTM(128) → BiLSTM(64) → Dropout(0.4) → cabezas específicas por tarea. Encoder compartido con loss total = $0.7 \cdot \text{Loss_rating} + 0.3 \cdot \text{Loss_spoiler}$.

DistilBERT Fine-tuning:

distilbert-base-uncased (66M parámetros, pre-entrenado en Wikipedia+BookCorpus) → token [CLS] (768 dim) → Dropout(0.1) → cabezas lineales. Fine-tuning en 2 fases: (1) solo cabezas congelando BERT (3 épocas, lr=1e-3); (2) últimas 2 capas descongeladas (5 épocas, lr=2e-5).

4. Training Procedure

Parámetro	MLP	BiLSTM	DistilBERT
Loss rating	CrossEntropy	CrossEntropy	CrossEntropy
Loss spoiler	BCEWithLogits	BCEWithLogits	BCEWithLogits

Optimizer	Adam (lr=1e-3)	Adam (lr=1e-3)	Adam (lr=2e-5)
Batch size	256	64	32
Épocas	10	10 (ES=3)	3+5 (2 fases)
Hardware	Apple M5 (MPS)	Apple M5 (MPS)	Apple M5 (MPS)
Regularización	Dropout 0.3	Dropout 0.4 + Grad clip	Dropout 0.1

5. Validation Strategy

Se monitoreó la val loss después de cada época. Para el BiLSTM se implementó early stopping (patience=3) guardando el mejor checkpoint por val loss. Para DistilBERT se guardó el mejor modelo de la Fase 2. Métricas de selección: accuracy y MAE para rating, F1-score para spoiler (dado el desbalance de clases: 94.1% sin spoiler vs 5.9% con spoiler).

6. Results

Modelo	Acc Rating	MAE Rating	F1 Spoiler
MLP + TF-IDF	0.457	0.747	0.078
BiLSTM Multitarea	0.486	0.672	0.000
DistilBERT	0.549	0.601	0.000

7. Error Analysis

El MLP mostró overfitting severo (train loss 0.09 vs val loss 2.10 en época 10), confirmando que TF-IDF no captura dependencias contextuales. El BiLSTM mejoró la estabilidad gracias al early stopping y gradient clipping, pero el F1 de spoiler cayó a 0 por el desbalance extremo de clases. DistilBERT obtuvo el mejor rendimiento en rating (54.9% acc, MAE 0.601) gracias a su pre-entrenamiento en BookCorpus. El F1 de spoiler en 0 para los tres modelos indica que el desbalance (94/6%) requeriría técnicas adicionales como oversampling o class weights ajustados específicamente para la tarea binaria.

8. References

- Wan, M. & McAuley, J. (2018). Item Recommendation on Monotonic Behavior Chains. RecSys.
- Wan, M. et al. (2019). Fine-Grained Spoiler Detection from Large-Scale Review Corpora. ACL.
- Sanh, V. et al. (2019). DistilBERT, a distilled version of BERT. NeurIPS Workshop.
- Hartmann, J. (2022). emotion-english-distilroberta-base. HuggingFace.

AI Usage Statement

During the development of this project, Claude (Anthropic) was used as an AI assistant. It supported: coding and debugging of preprocessing pipelines, model architectures and training loops; explanation of concepts (BiLSTM, fine-tuning strategies, class imbalance handling); and documentation (README, report structure). All code was reviewed, validated and executed by the team. The team is fully responsible for understanding and explaining all submitted work.