

NLP Multitarea sobre Reseñas de Libros Goodreads

Predicción de rating · Detección de spoilers · Clasificación de emociones

Redes Neuronales 2026 — Universidad EAFIT — Isabella Idarraga Botero · Juan Esteban Alzate Ospina

1. Problem Statement

Las plataformas de reseñas literarias como Goodreads generan millones de textos con información valiosa pero dispersa. Este proyecto aborda tres tareas de NLP de forma simultánea sobre el mismo corpus de reseñas del género Young Adult: (1) predicción de rating (1–5 estrellas), tarea que va más allá del análisis de sentimiento binario; (2) detección de spoilers, clasificación binaria con alto impacto práctico; y (3) clasificación de emociones (joy, sadness, anger, surprise, fear, disgust), cuyas etiquetas se generan con el modelo j-hartmann/emotion-english-distilroberta-base como paso de preprocesamiento. La hipótesis es que las tres señales están correlacionadas y que un encoder compartido puede capturar esa estructura común.

2. Dataset & Data Splitting

Goodreads Book Graph Dataset (UCSD, Wan & McAuley, RecSys'18 / ACL'19), compuesto por dos subsets: Young Adult reviews (2,389,900 reseñas) para rating y emoción, y Spoiler dataset (~1,300,000 reseñas) para detección de spoilers, cruzado por review_id. El input principal es review_text (texto libre), con labels rating (1–5), has_spoiler (booleano extraído de marcas implícitas en el texto) y emotion (pseudo-label generado por modelo pre-entrenado). Muestreo estratificado por rating: 100k reseñas para MLP y BiLSTM, 50k para DistilBERT.

Split	Train	Validation	Test
Tamaño	70,000	15,000	15,000
Porcentaje	70%	15%	15%

Estratificado por clase de rating para preservar la distribución en los tres conjuntos.

3. Model Architecture

Se implementaron tres arquitecturas de complejidad creciente. Las tareas 1 (rating) y 2 (spoiler) se entrenan conjuntamente con cabezas de salida dedicadas; la tarea 3 (emoción) se resuelve por inferencia directa con el modelo pre-entrenado, sin entrenamiento adicional.

MLP + TF-IDF (Baseline): TF-IDF (20k tokens) → Dense(256)+ReLU+Dropout(0.3) → Dense(128)+ReLU+Dropout(0.3) → cabezas Dense(5)+Softmax (rating) y Dense(1)+Sigmoid (spoiler).

Bi-LSTM Multitarea: Embedding entrenable (20k×128) → BiLSTM(128) → BiLSTM(64) → Dropout(0.4) → cabezas específicas por tarea. Encoder compartido con loss total = 0.7·Loss_rating + 0.3·Loss_spoiler.

DistilBERT Fine-tuning: distilbert-base-uncased (66M parámetros, pre-entrenado en Wikipedia+BookCorpus) → token [CLS] (768 dim) → Dropout(0.1) → cabezas lineales. Fine-tuning en 2 fases: (1) solo cabezas congelando BERT (3 épocas, lr=1e-3); (2) últimas 2 capas descongeladas (5 épocas, lr=2e-5). **Decisión de diseño:** se eligió DistilBERT sobre BERT-base por mantener ~97% del rendimiento con 40% menos parámetros, viable con recursos limitados.

4. Training Procedure

Parámetro	MLP	BiLSTM	DistilBERT
Loss rating	CrossEntropy	CrossEntropy	CrossEntropy
Loss spoiler	BCEWithLogits	BCEWithLogits	BCEWithLogits
Optimizer	Adam (lr=1e-3)	Adam (lr=1e-3)	Adam (lr=2e-5)
Batch size	256	64	32
Épocas	10	10 (ES=3)	3+5 (2 fases)
Regularización	Dropout 0.3	Dropout 0.4 + Grad clip	Dropout 0.1
Hardware	Apple M5 (MPS)	Apple M5 (MPS)	Apple M5 (MPS)

Curvas de entrenamiento (loss y métricas vs época) disponibles en Results/02_VISUALIZACIONES/ (mlp_curves.png, bilstm_curves.png).

5. Validation Strategy

Se monitoreó la val loss después de cada época. Para el BiLSTM se implementó early stopping (patience=3) guardando el mejor checkpoint por val loss; para DistilBERT se guardó el mejor modelo de la Fase 2. Criterio de selección de modelo: mejor val loss. Métricas: accuracy y MAE para rating, F1-score para spoiler (apropiado dado el desbalance de clases: 94.1% sin spoiler vs 5.9% con

spoiler), accuracy y confianza promedio para emoción.

6. Results

Modelo	Acc Rating	MAE Rating	F1 Spoiler
MLP + TF-IDF	0.457	0.747	0.078
BiLSTM Multitarea	0.486	0.672	0.000
DistilBERT	0.549	0.601	0.000

Tarea 3 (emoción): inferencia sobre 15,000 reseñas del test set, confianza promedio 69.7%. Distribución: neutral 25.5%, joy 25.3%, sadness 13.9%, surprise 12.1%, disgust 12.1%, fear 6.4%, anger 4.9%. Mayor confianza en joy (78.3%), menor en neutral (62.8%).

Train vs Val vs Test: DistilBERT mantiene consistencia entre val y test (~0.55 acc), sin gap significativo. El MLP muestra el mayor gap train-val (ver Error Analysis).

7. Error Analysis (overfitting / underfitting)

El MLP mostró **overfitting severo**: la train loss cayó a ~0.09 mientras la val loss subió a ~2.0 en la época 10, con la accuracy de validación degradándose de 0.52 a 0.45 — TF-IDF memoriza el vocabulario de entrenamiento sin capturar dependencias contextuales generalizables. El BiLSTM mejoró la estabilidad gracias al early stopping y al gradient clipping, deteniéndose antes de sobreajustar. El **F1 de spoiler en 0.0** para BiLSTM y DistilBERT es el fallo más notorio: ambos colapsaron a predecir siempre la clase mayoritaria porque, con un desbalance de 94/6%, la tarea de spoiler aporta gradiente insuficiente en la loss combinada. El MLP fue paradójicamente más robusto (F1=0.078) al no poder sobre-optimizar el rating. **Mitigación propuesta:** weighted cross-entropy con pesos inversamente proporcionales a la frecuencia de clase, oversampling de la clase positiva, o usar la emoción predicha (surprise correlaciona con spoilers) como feature auxiliar.

8. References

- Wan, M. & McAuley, J. (2018). *Item Recommendation on Monotonic Behavior Chains*. RecSys.
- Wan, M. et al. (2019). *Fine-Grained Spoiler Detection from Large-Scale Review Corpora*. ACL.
- Sanh, V. et al. (2019). *DistilBERT, a distilled version of BERT*. NeurIPS Workshop.
- Hartmann, J. (2022). *emotion-english-distilroberta-base*. HuggingFace.

AI Usage Statement

Durante el desarrollo de este proyecto se utilizó Claude (Anthropic) como asistente de IA. Apoyó en: escritura y depuración de código (pipelines de preprocesamiento, arquitecturas y loops de entrenamiento), explicación de conceptos (BiLSTM, estrategias de fine-tuning, manejo de desbalance de clases) y documentación (README, estructura del reporte). Todo el código fue revisado, validado y ejecutado por el equipo, que es plenamente responsable de comprender y explicar la totalidad del trabajo entregado.